Лекция 4
Стандарт MPI
Производные типы данных (derived data types)

Курносов Михаил Георгиевич

E-mail: mkurnosov@gmail.com
WWW: www.mkurnosov.net

Курс «Параллельные вычислительные технологии»
Сибирский государственный университет телекоммуникаций и информатики (г. Новосибирск)
Осенний семестр, 2017

Пользовательские типы данных (MPI Derived Data Types)

- Как передать структуру C/C++ в другой процесс?
- Как передать другом процессу столбец матрицы?
- (в C/C++ массивы хранятся в памяти строка за строкой – row-major order,
- в Fortran столбец за столбцом – column-major order)
- Как реализовать прием сообщений различных размеров
- (заголовок сообщения содержит его тип, размер)?

Пользовательские типы данных (MPI Derived Data Types)

```
typedef struct {
    double x;
    double y;
    double z;
    double f;
    int data[8];
} particle_t;

int main(int argc, char **argv)
{
    int rank;
    MPI_Init(&argc, &argv);
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);

    int nparticles = 1000;
    particle_t *particles = malloc(sizeof(*particles) * nparticles);
```

Как передать массив частиц другому процессу?

Пользовательские типы данных (MPI Derived Data Types)

```
/* Create data type for message of type particle_t */
MPI_Datatype types[5] = {MPI_DOUBLE, MPI_DOUBLE, MPI_DOUBLE, MPI_DOUBLE,
                         MPI_INT};
int blocklens[5] = {1, 1, 1, 1, 8};

MPI_Aint displs[0];
displs[0] = offsetof(particle_t, x);
displs[1] = offsetof(particle_t, y);
displs[2] = offsetof(particle_t, z);
displs[3] = offsetof(particle_t, f);
displs[4] = offsetof(particle_t, data);

MPI_Datatype parttype;
MPI_Type_create_struct(5, blocklens, displs,
                       types, &parttype);
MPI_Type_commit(&parttype);
```

```
                    // size = 64
struct {
    double x;     // offset 0
    double y;     // offset 8
    double z;     // offset 16
    double f;     // offset 24
    int data[8]; // offset 32
}
```

Компилятор выравнивает структуру

```
                    // size = 72
struct {
    double x;     // offset 0
    double y;     // offset 8
    double z;     // offset 16
    int type      // offset 24
    double f;     // offset 32
    int data[8]; // offset 40
}
```

Пользовательские типы данных (MPI Derived Data Types)

```
    /* Init particles */
    if (rank == 0) {
        // Random positions in simulation box
        for (int i = 0; i < nparticles; i++) {
            particles[i].x = rand() % 10000;
            particles[i].y = rand() % 10000;
            particles[i].z = rand() % 10000;
            particles[i].f = 0.0;
        }
    }
    MPI_Bcast(particles, nparticles, parttype, 0, MPI_COMM_WORLD);

    // code ...

    MPI_Type_free(&parttype);
    free(particles);
    MPI_Finalize( );
    return 0;
}
```

MPI_Type_contiguous

```
int MPI_Type_contiguous(int count, MPI_Datatype oldtype,
                        MPI_Datatype *newtype)
```

- Непрерывная последовательность в памяти (массив) элементов типа oldtype
- Одномерный массив

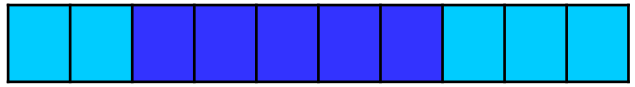

contig.

Пример

- oldtype = {(double, 0), (char, 8)}
  (1 double и 1 char, 0 и 8 — смещения)
- MPI_Type_contiguous(3, MPI_Datatype oldtype, &newtype)

- newtype = {(double, 0), (char, 8), (double, 16), (char, 24), (double, 32), (char, 40)}

Пользовательские типы данных (MPI Derived Data Types)

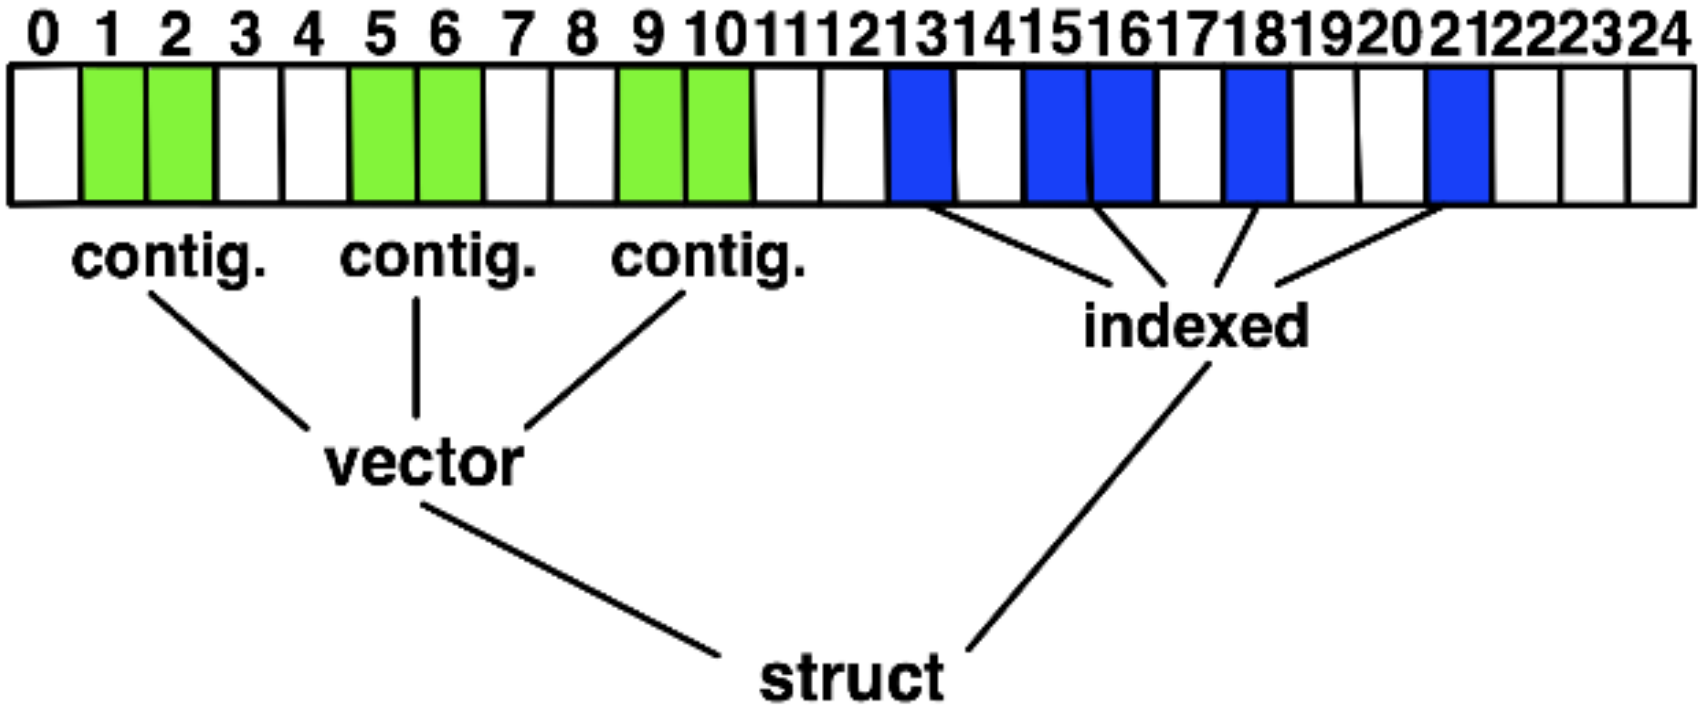

T. Hoefler. Advanced Parallel Programming with MPI // EuroMPI'14 Tutorial http://htor.inf.ethz.ch/teaching/mpi_tutorials/eurompi14/

Пользовательские типы данных (MPI Derived Data Types)

```
int MPI_Type_vector(int count, int blocklength, int stride,
                    MPI_Datatype oldtype, MPI_Datatype *newtype)

int MPI_Type_indexed(int count, const int array_of_blocklengths[],
                     const int array_of_displacements[],
                     MPI_Datatype oldtype, MPI_Datatype *newtype)

int MPI_Type_create_struct(int count,
                           const int array_of_blocklengths[],
                           const MPI_Aint array_of_displacements[],
                           const MPI_Datatype array_of_types[],
                           MPI_Datatype *newtype)

int MPI_Type_create_subarray(int ndims, const int array_of_sizes[],
                             const int array_of_subsizes[],
                             const int array_of_starts[],
                             int order, MPI_Datatype oldtype,
                             MPI_Datatype *newtype)
...
```

Выбор типа данных

1. Предопределенные типы (MPI_DOUBLE, MPI_INT, MPI_CHAR, ...)
2. contig
3. vector
4. index_block
5. index
6. struct

Передача строк и столбцов матрицы

```
double *grid = malloc(ny * nx * sizeof(double))
```

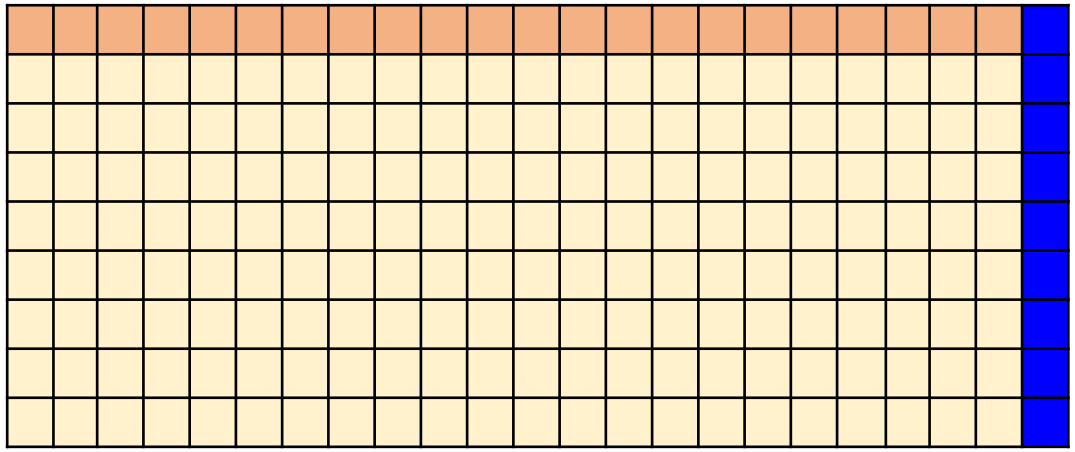

```
// Top and bottom borders type
MPI_Datatype row;
MPI_Type_contiguous(nx, MPI_DOUBLE, &row);
MPI_Type_commit(&row);


// Column type
MPI_Datatype col;
MPI_Type_vector(ny, 1, nx, MPI_DOUBLE, &col);
MPI_Type_commit(&col);
```

```
MPI_Recv(&grid[0], 1, row, rank, 0, comm, MPI_STATUS_IGNORE); // recv top row

MPI_Send(&grid[nx - 1], 1, col, rank, 0, comm); // send right column


MPI_Type_free(&row);
MPI_Type_free(&col);
```

Упаковка данных (MPI_Pack)

```
int main(int argc, char **argv)
{
    int rank, packsize, position;
    int a;
    double b;
    uint8_t packbuf[100];

    MPI_Init(&argc, &argv);
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);

    if (rank == 0) {
        a = 15;
        b = 3.14;
```

Как передать int a и double b одним сообщением ?

Упаковка данных (MPI_Pack)

```
        packsize = 0; /* Pack data into the buffer */
        MPI_Pack(&a, 1, MPI_INT, packbuf, 100, &packsize, MPI_COMM_WORLD);
        MPI_Pack(&b, 1, MPI_DOUBLE, packbuf, 100, &packsize, MPI_COMM_WORLD);
    }

    MPI_Bcast(&packsize, 1, MPI_INT, 0, MPI_COMM_WORLD);
    MPI_Bcast(packbuf, packsize, MPI_PACKED, 0, MPI_COMM_WORLD);
    if (rank != 0) {
        position = 0; /* Unpack data */
        MPI_Unpack(packbuf, packsize, &position, &a, 1, MPI_INT, MPI_COMM_WORLD);
        MPI_Unpack(packbuf, packsize, &position, &b, 1, MPI_DOUBLE,
                   MPI_COMM_WORLD);
    }
    printf("Process %d unpacked %d and %lf\n", rank, a, b);
    MPI_Finalize( );
    return 0;
}
```

Обработка изображения (contrast)

height

width

1) Вычисляется среднее квадратичное значений всех пикселей (RMS)

RMS = sqrt(sum(L[i][j] * L[i][j]) / (H * W))

2) Каждый пиксель L[i,j] преобразуется

L[i,j] = 2 * L[i, j] - RMS
if (L[i,j] < 0) then L[i,j] = 0
if (L[i,j] > 255) then L[i,j] = 255

Обработка изображения (contrast)

```
npixels = width * height;
npixels_per_process = npixels / commsize;
```

1D decomposition

Обработка изображения (contrast)

```
int main(int argc, char *argv[]) {
    MPI_Init(&argc, &argv);
    int rank, commsize;
    MPI_Comm_rank(MPI_COMM_WORLD, &rank);
    MPI_Comm_size(MPI_COMM_WORLD, &commsize);

    int width, height, npixels, npixels_per_process;
    uint8_t *pixels = NULL;
    if (rank == 0) {
        width = 15360;  // 15360 x 8640: 16K Digital Cinema (UHDTV) ~ 127 MiB
        height = 8640;
        npixels = width * height;
        pixels = xmalloc(sizeof(*pixels) * npixels);
        for (int i = 0; i < npixels; i++)
            pixels[i] = rand() % 255;
    }

    MPI_Bcast(&npixels, 1, MPI_INT, 0, MPI_COMM_WORLD);  // Send size of image
    npixels_per_process = npixels / commsize;
    uint8_t *rbuf = xmalloc(sizeof(*rbuf) * npixels_per_process);
    // Send a part of image to each process
    MPI_Scatter(pixels, npixels_per_process, MPI_UINT8_T, rbuf, npixels_per_process, MPI_UINT8_T,
                0, MPI_COMM_WORLD);
```

Обработка изображения (contrast)

```
int sum_local = 0;
for (int i = 0; i < npixels_per_process; i++)
    sum_local += rbuf[i] * rbuf[i];

/* Calculate global sum of the squares */
int sum = 0;
// MPI_Reduce(&sum_local, &sum, 1, MPI_INT, MPI_SUM, 0, MPI_COMM_WORLD);
MPI_Allreduce(&sum_local, &sum, 1, MPI_INT, MPI_SUM, MPI_COMM_WORLD);

double rms;
// if (rank == 0)
rms = sqrt((double)sum / (double)npixels);

//MPI_Bcast(&rms, 1, MPI_DOUBLE, 0, MPI_COMM_WORLD);
```

Обработка изображения (contrast)

```
    /* Contrast operation on subimage */
    for (int i = 0; i < npixels_per_process; i++) {
        int pixel = 2 * rbuf[i] - rms;
        if (pixel < 0)
            rbuf[i] = 0;
        else if (pixel > 255)
            rbuf[i] = 255;
        else
            rbuf[i] = pixel;
    }
    MPI_Gather(rbuf, npixels_per_process, MPI_UINT8_T, pixels,
               npixels_per_process, MPI_UINT8_T, 0, MPI_COMM_WORLD);
    if (rank == 0)
        // Save image...

    free(rbuf);
    if (rank == 0)
        free(pixels);
    MPI_Finalize();
}
```

Обработка изображения (contrast)

Равномерно ли пиксели изображения распределяются по процессам?
npixels_per_process = npixels / commsize;

Загрузка исходного изображения
a) Корневой процесс загружает изображение и рассылает части остальным (изображение может не поместиться в память одного узла)
b) Каждый процесс загружает часть изображения (MPI I/O, NFS, Lustre)

Обработка изображения
Вычисление RMS: MPI_Reduce + MPI_Bcast или MPI_Allreduce

Сохранение изображения
Сборка Gather — изображение формируется в памяти процесс 0
Сборка Send/Recv — части изображения последовательно сохраняются в файл

Домашнее чтение

Pavan Balaji, William Gropp, Torsten Hoefler, Rajeev Thakur. **Advanced MPI Programming** // Tutorial at SC14, November 2014, http://www.mcs.anl.gov/~thakur/sc14-mpi-tutorial/

Torsten Hoefler. **Advanced MPI 2.2 and 3.0 Tutorial** // http://htor.inf.ethz.ch/teaching/mpi_tutorials/cscs12/hoefler_tutorial_advanced-mpi-2.2-and-mpi-3.0_cscs.pdf